

# Symulacje w finansach, część 2

## Metody redukcji wariancji

Olga Bączkowska

4.04.2022

## Błąd standardowy estymacji Monte Carlo

Przypomnijmy, e jeśli chcemy wyestymować wartość oczekiwaną ( $\psi(X)$ ) przy pomocy estymatora  $\hat{\alpha}_N = \frac{1}{N} \sum_{i=1}^N \psi(x_i)$ , gdzie  $x_i$  s niezależnymi próbkami z rozkładu  $f_X$ , to wariancja estymatora wynosi

$$\text{Var}(\hat{\alpha}_N) = \frac{\sigma(\psi(X))}{N}$$

## Błąd standardowy estymacji Monte Carlo

Przypomnijmy, e jeśli chcemy wyestymować wartość oczekiwaną ( $\psi(X)$ ) przy pomocy estymatora  $\hat{\alpha}_N = \frac{1}{N} \sum_{i=1}^N \psi(x_i)$ , gdzie  $x_i$  s niezależnymi próbkami z rozkładu  $f_X$ , to wariancja estymatora wynosi

$$\text{Var}(\hat{\alpha}_N) = \frac{\sigma(\psi(X))}{N}$$

Możemy zastąpić (często nieznane)  $\sigma(\psi(X))$  odchyleniem standardowym próbki

$$s_N = \sqrt{\frac{1}{N} \sum_{i=1}^N \psi(x_i)^2 - \left( \frac{1}{N} \sum_{i=1}^N \psi(x_i) \right)^2}.$$

## Błąd standardowy estymacji Monte Carlo

Przypomnijmy, e jeśli chcemy wyestymować wartość oczekiwaną ( $\psi(X)$ ) przy pomocy estymatora  $\hat{\alpha}_N = \frac{1}{N} \sum_{i=1}^N \psi(x_i)$ , gdzie  $x_i$  s niezależnymi próbkami z rozkładu  $f_X$ , to wariancja estymatora wynosi

$$\text{Var}(\hat{\alpha}_N) = \frac{\sigma(\psi(X))}{N}$$

Możemy zastąpić (często nieznane)  $\sigma(\psi(X))$  odchyleniem standardowym próbki

$$s_N = \sqrt{\frac{1}{N} \sum_{i=1}^N \psi(x_i)^2 - \left( \frac{1}{N} \sum_{i=1}^N \psi(x_i) \right)^2}.$$

Wyrażenie  $\epsilon_N = \frac{s_N}{\sqrt{N}}$  nazywamy błędem standardowym.

## Błąd standardowy estymacji Monte Carlo

Przypomnijmy, e jeśli chcemy wyestymować wartość oczekiwaną ( $\psi(X)$ ) przy pomocy estymatora  $\hat{\alpha}_N = \frac{1}{N} \sum_{i=1}^N \psi(x_i)$ , gdzie  $x_i$  s niezależnymi próbkami z rozkładu  $f_X$ , to wariancja estymatora wynosi

$$\text{Var}(\hat{\alpha}_N) = \frac{\sigma(\psi(X))}{N}$$

Możemy zastąpić (często nieznane)  $\sigma(\psi(X))$  odchyleniem standardowym próbki

$$s_N = \sqrt{\frac{1}{N} \sum_{i=1}^N \psi(x_i)^2 - \left( \frac{1}{N} \sum_{i=1}^N \psi(x_i) \right)^2}.$$

Wyrażenie  $\epsilon_N = \frac{s_N}{\sqrt{N}}$  nazywamy błędem standardowym.

Im mniejszy błąd standardowy tym większa dokładność kalkulacji.

## Błąd standardowy estymacji Monte Carlo

Przypomnijmy, e jeśli chcemy wyestymować wartość oczekiwaną ( $\psi(X)$ ) przy pomocy estymatora  $\hat{\alpha}_N = \frac{1}{N} \sum_{i=1}^N \psi(x_i)$ , gdzie  $x_i$  s niezależnymi próbkami z rozkładu  $f_X$ , to wariancja estymatora wynosi

$$\text{Var}(\hat{\alpha}_N) = \frac{\sigma(\psi(X))}{N}$$

Możemy zastąpić (często nieznane)  $\sigma(\psi(X))$  odchyleniem standardowym próbki

$$s_N = \sqrt{\frac{1}{N} \sum_{i=1}^N \psi(x_i)^2 - \left( \frac{1}{N} \sum_{i=1}^N \psi(x_i) \right)^2}.$$

Wyrażenie  $\epsilon_N = \frac{s_N}{\sqrt{N}}$  nazywamy błędem standardowym.

Im mniejszy błąd standardowy tym większa dokładność kalkulacji.

Nie ma jednej uniwersalnej metody redukcji wariancji. Zwykle największy wzrost efektywności możemy uzyskać korzystając ze szczególnych własności danego problemu czy modelu.

## Antithetic sampling

Metoda *antithetic sampling* polega na redukcji wariancji poprzez wprowadzenie ujemnej zależności między parami próbek. Jeśli nasza realizacja  $Y_i$  zależy od próbki  $Z_i$  ( $Y_i = Y(Z_i)$ ), to do obliczeń używamy również  $\tilde{Y}_i = Y(-Z_i)$ .

## Antitethic sampling

Metoda *antithetic sampling* polega na redukcji wariancji poprzez wprowadzenie ujemnej zależności między parami próbek. Jeśli nasza realizacja  $Y_i$  zależy od próbki  $Z_i$  ( $Y_i = Y(Z_i)$ ), to do obliczeń używamy również  $\tilde{Y}_i = Y(-Z_i)$ .

$$\hat{Y}_{AV} = \frac{1}{2n} \left( \sum_{i=1}^n Y_i + \sum_{i=1}^n \tilde{Y}_i \right) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i + \tilde{Y}_i}{2} \right)$$



## Antithetic sampling

Metoda *antithetic sampling* polega na redukcji wariancji poprzez wprowadzenie ujemnej zależności między parami próbek. Jeśli nasza realizacja  $Y_i$  zależy od próbki  $Z_i$  ( $Y_i = Y(Z_i)$ ), to do obliczeń używamy również  $\tilde{Y}_i = Y(-Z_i)$ .

$$\hat{Y}_{AV} = \frac{1}{2n} \left( \sum_{i=1}^n Y_i + \sum_{i=1}^n \tilde{Y}_i \right) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i + \tilde{Y}_i}{2} \right)$$

A zatem z centralnego twierdzenia granicznego

$$\frac{\hat{Y}_{AV} - \mathbb{E}(Y)}{\sigma_{AV}/\sqrt{n}} \rightarrow N(0, 1), \quad \sigma_{AV}^2 = \text{Var} \left( \frac{Y_1 + \tilde{Y}_1}{2} \right)$$

## Antithetic sampling

Metoda *antithetic sampling* polega na redukcji wariancji poprzez wprowadzenie ujemnej zależności między parami próbek. Jeśli nasza realizacja  $Y_i$  zależy od próbki  $Z_i$  ( $Y_i = Y(Z_i)$ ), to do obliczeń używamy również  $\tilde{Y}_i = Y(-Z_i)$ .

$$\hat{Y}_{AV} = \frac{1}{2n} \left( \sum_{i=1}^n Y_i + \sum_{i=1}^n \tilde{Y}_i \right) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i + \tilde{Y}_i}{2} \right)$$

A zatem z centralnego twierdzenia granicznego

$$\frac{\hat{Y}_{AV} - \mathbb{E}(Y)}{\sigma_{AV}/\sqrt{n}} \rightarrow N(0, 1), \quad \sigma_{AV}^2 = \text{Var} \left( \frac{Y_1 + \tilde{Y}_1}{2} \right)$$

Zakładając, że "koszt" wygenerowania pary  $(Y_i, \tilde{Y}_i)$  jest dwa razy większy niż wygenerowania  $Y_i$ , metoda redukuje wariancję jeśli

$$\text{Var} \left( \hat{Y}_{AV} \right) < \text{Var} \left( \frac{1}{2n} \sum_{i=1}^{2n} Y_i \right) \Leftrightarrow \text{Cov}(Y_i, \tilde{Y}_i) < 0.$$

## Antithetic sampling

Metoda *antithetic sampling* polega na redukcji wariancji poprzez wprowadzenie ujemnej zależności między parami próbek. Jeśli nasza realizacja  $Y_i$  zależy od próbki  $Z_i$  ( $Y_i = Y(Z_i)$ ), to do obliczeń używamy również  $\tilde{Y}_i = Y(-Z_i)$ .

$$\hat{Y}_{AV} = \frac{1}{2n} \left( \sum_{i=1}^n Y_i + \sum_{i=1}^n \tilde{Y}_i \right) = \frac{1}{n} \sum_{i=1}^n \left( \frac{Y_i + \tilde{Y}_i}{2} \right)$$

A zatem z centralnego twierdzenia granicznego

$$\frac{\hat{Y}_{AV} - \mathbb{E}(Y)}{\sigma_{AV}/\sqrt{n}} \rightarrow N(0, 1), \quad \sigma_{AV}^2 = \text{Var} \left( \frac{Y_1 + \tilde{Y}_1}{2} \right)$$

Zakładając, że "koszt" wygenerowania pary  $(Y_i, \tilde{Y}_i)$  jest dwa razy większy niż wygenerowania  $Y_i$ , metoda redukuje wariancję jeśli

$$\text{Var} \left( \hat{Y}_{AV} \right) < \text{Var} \left( \frac{1}{2n} \sum_{i=1}^{2n} Y_i \right) \Leftrightarrow \text{Cov}(Y_i, \tilde{Y}_i) < 0.$$

Ten warunek zachodzi np. gdy  $Y(Z)$  jest monotoniczne względem  $Z$ .

## Moment matching

Niech  $S(t)$  będzie procesem cen (niepłacącego dywidend) aktywa, a  $r$  stałą stopą wolną od ryzyka. Wiemy, że

$$\mathbb{E}(S(t)) = e^{rt} S(0).$$

Założmy, że wysymulowaliśmy  $n$  niezależnych próbek  $S^1, \dots, S^n$ .

## Moment matching

Niech  $S(t)$  będzie procesem cen (niepłacącego dywidend) aktywa, a  $r$  stałą stopą wolną od ryzyka. Wiemy, że

$$\mathbb{E}(S(t)) = e^{rt} S(0).$$

Założmy, że wysymulowaliśmy  $n$  niezależnych próbek  $S^1, \dots, S^n$ . Przeważnie mamy

$$e^{-rt} \bar{S}(t) = e^{-rt} \frac{1}{n} \sum_{i=1}^n S_i(t) \neq S(0). \quad (1)$$

## Moment matching

Niech  $S(t)$  będzie procesem cen (niepłacącego dywidend) aktywa, a  $r$  stałą stopą wolną od ryzyka. Wiemy, że

$$\mathbb{E}(S(t)) = e^{rt} S(0).$$

Założmy, że wysymulowaliśmy  $n$  niezależnych próbek  $S^1, \dots, S^n$ . Przeważnie mamy

$$e^{-rt} \bar{S}(t) = e^{-rt} \frac{1}{n} \sum_{i=1}^n S_i(t) \neq S(0). \quad (1)$$

W problemie wyceny instrumentów pochodnych zwykle celem jest określenie wartości instrumentu w odniesieniu do instrumentów bazowych. Brak równości w (1) możemy rozumieć jako potencjalną możliwość arbitrażu.

## Moment matching

Niech  $S(t)$  będzie procesem cen (niepłacącego dywidend) aktywa, a  $r$  stałą stopą wolną od ryzyka. Wiemy, że

$$\mathbb{E}(S(t)) = e^{rt} S(0).$$

Założmy, że wysymulowaliśmy  $n$  niezależnych próbek  $S^1, \dots, S^n$ . Przeważnie mamy

$$e^{-rt} \bar{S}(t) = e^{-rt} \frac{1}{n} \sum_{i=1}^n S_i(t) \neq S(0). \quad (1)$$

W problemie wyceny instrumentów pochodnych zwykle celem jest określenie wartości instrumentu w odniesieniu do instrumentów bazowych. Brak równości w (1) możemy rozumieć jako potencjalną możliwość arbitrażu. Jednym z rozwiązań tego problemu jest transformacja wysymulowanych ścieżek:

$$\tilde{S}(t) = S_i(t) \frac{\mathbb{E}(S(t))}{\bar{S}(t)}, \quad i = 1, \dots, n;$$

## Moment matching

Niech  $S(t)$  będzie procesem cen (niepłacącego dywidend) aktywa, a  $r$  stałą stopą wolną od ryzyka. Wiemy, że

$$\mathbb{E}(S(t)) = e^{rt} S(0).$$

Założmy, że wysymulowaliśmy  $n$  niezależnych próbek  $S^1, \dots, S^n$ . Przeważnie mamy

$$e^{-rt} \bar{S}(t) = e^{-rt} \frac{1}{n} \sum_{i=1}^n S_i(t) \neq S(0). \quad (1)$$

W problemie wyceny instrumentów pochodnych zwykle celem jest określenie wartości instrumentu w odniesieniu do instrumentów bazowych. Brak równości w (1) możemy rozumieć jako potencjalną możliwość arbitrażu. Jednym z rozwiązań tego problemu jest transformacja wysymulowanych ścieżek:

$$\tilde{S}(t) = S_i(t) \frac{\mathbb{E}(S(t))}{\bar{S}(t)}, \quad i = 1, \dots, n;$$

lub

$$\tilde{S}(t) = S_i(t) + \mathbb{E}(S(t)) - \bar{S}(t), \quad i = 1, \dots, n.$$



## Moment matching - przykład

Dla standardowego procesu Wienera transformacja

$$\tilde{W}_i(t) = \frac{W_i(t) - \hat{W}(t)}{s(t)/\sqrt{t}},$$

gdzie  $s(t)$  jest odchyleniem standardowym próbki, daje dopasowanie dwóch pierwszych momentów, ale nie zapewnia niezależności przyrostów.

## Moment matching - przykład

Dla standardowego procesu Wienera transformacja

$$\tilde{W}_i(t) = \frac{W_i(t) - \hat{W}(t)}{s(t)/\sqrt{t}},$$

gdzie  $s(t)$  jest odchyleniem standardowym próbki, daje dopasowanie dwóch pierwszych momentów, ale nie zapewnia niezależności przyrostów. Jeśli przyjmiemy że

$$W_i(t_k) = \sum_{j=1}^k \sqrt{t_j - t_{j-1}} Z_{ij}, \quad \{Z_{ij}\} \text{ i.i.d. z } N(0, 1),$$

$$\hat{Z}_j = \frac{1}{n} \sum_{i=1}^n Z_{ij}, \quad s_j^2 = \frac{1}{n-1} \sum_{i=1}^n (Z_{ij})^2 - \hat{Z}_j^2$$

zachowujemy niezależność przyrostów.

## "Zmienne kontrolne" (Control Variates)

Założmy, że mamy  $n$  realizacji zmiennej losowej  $Y - (Y_1, \dots, Y_n)$  i chcemy wyestymować  $\mathbb{E}(Y)$  oraz że dla każdej realizacji  $Y_i$  mamy dodatkowo realizację innej zmiennej losowej  $X - X_i$ . Jeśli pary  $(X_i, Y_i)$  są i.i.d., a  $\mathbb{E}(X)$  jest znane i zdefiniujemy

$$Y_i(b) = Y_i - b(X_i - \mathbb{E}(X)),$$

## "Zmienne kontrolne" (Control Variates)

Założmy, że mamy  $n$  realizacji zmiennej losowej  $Y - (Y_1, \dots, Y_n)$  i chcemy wyestymować  $\mathbb{E}(Y)$  oraz że dla każdej realizacji  $Y_i$  mamy dodatkowo realizację innej zmiennej losowej  $X - X_i$ . Jeśli pary  $(X_i, Y_i)$  są i.i.d., a  $\mathbb{E}(X)$  jest znane i zdefiniujemy

$$Y_i(b) = Y_i - b(X_i - \mathbb{E}(X)),$$

możemy estymować  $\mathbb{E}(Y)$  jako

$$\bar{Y}(b) = \bar{Y} - b(\bar{X} - \mathbb{E}(X)) = \frac{1}{n} \sum_{i=1}^n (Y_i - b(X_i - \mathbb{E}(X))).$$

## "Zmienne kontrolne" (Control Variates)

Założmy, że mamy  $n$  realizacji zmiennej losowej  $Y - (Y_1, \dots, Y_n)$  i chcemy wyestymować  $\mathbb{E}(Y)$  oraz że dla każdej realizacji  $Y_i$  mamy dodatkowo realizację innej zmiennej losowej  $X - X_i$ . Jeśli pary  $(X_i, Y_i)$  są i.i.d., a  $\mathbb{E}(X)$  jest znane i zdefiniujemy

$$Y_i(b) = Y_i - b(X_i - \mathbb{E}(X)),$$

możemy estymować  $\mathbb{E}(Y)$  jako

$$\bar{Y}(b) = \bar{Y} - b(\bar{X} - \mathbb{E}(X)) = \frac{1}{n} \sum_{i=1}^n (Y_i - b(X_i - \mathbb{E}(X))).$$

Tak określony estymator jest nieobciążony i zgodny z prawdopodobieństwem 1 a jego wariancja wynosi

$$\text{Var}(\bar{Y}(b)) = \frac{\sigma_Y^2 - 2b\sigma_X\sigma_Y\rho_{XY} + b^2\sigma_X^2}{n}.$$

## Control Variates - redukcja wariancji

Optymalny współczynnik  $b$  minimalizujący wariancję jest dany wzorem:

$$b^* = \frac{\sigma_Y}{\sigma_X} \rho_{XY} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

## Control Variates - redukcja wariancji

Optymalny współczynnik  $b$  minimalizujący wariancję jest dany wzorem:

$$b^* = \frac{\sigma_Y}{\sigma_X} \rho_{XY} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

Stosunek wariancji optymalnego estymatora do wariancji estymatora "niekontrolowanego" wynosi

$$\frac{\text{Var}(\bar{Y} - b^*(\bar{X} - \mathbb{E}(X)))}{\text{Var}(\bar{Y})} = 1 - \rho_{XY}^2.$$

## Control Variates - redukcja wariancji

Optymalny współczynnik  $b$  minimalizujący wariancję jest dany wzorem:

$$b^* = \frac{\sigma_Y}{\sigma_X} \rho_{XY} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

Stosunek wariancji optymalnego estymatora do wariancji estymatora "niekontrolowanego" wynosi

$$\frac{\text{Var}(\bar{Y} - b^*(\bar{X} - \mathbb{E}(X)))}{\text{Var}(\bar{Y})} = 1 - \rho_{XY}^2.$$

Aby uzyskać dużą redukcję wariancji potrzebujemy zmiennych kontrolnych silnie skorelowanych z  $Y$ .



## Control Variates - redukcja wariancji

Optymalny współczynnik  $b$  minimalizujący wariancję jest dany wzorem:

$$b^* = \frac{\sigma_Y}{\sigma_X} \rho_{XY} = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}$$

Stosunek wariancji optymalnego estymatora do wariancji estymatora "niekontrolowanego" wynosi

$$\frac{\text{Var}(\bar{Y} - b^*(\bar{X} - \mathbb{E}(X)))}{\text{Var}(\bar{Y})} = 1 - \rho_{XY}^2.$$

Aby uzyskać dużą redukcję wariancji potrzebujemy zmiennych kontrolnych silnie skorelowanych z  $Y$ . W praktyce najczęściej nie znamy  $\sigma_Y$  i  $\rho_{XY}$ . Zastępując te wartości ich standardowymi estymatorami mamy

$$\hat{b}_n = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}.$$

przy czym  $\hat{b}_n \rightarrow b$  z prawdopodobieństwem 1.

## Control Variates - przykłady

Klasyczne przykłady użycie metody control variates:

## Control Variates - przykłady

Klasyczne przykłady użycie metody control variates:

- ▶ instrument bazowy jako "zmienna kontrolna" dla zdyskontowanej wypłaty z opcji  $Y$ :

$$\bar{Y}(b_n) = \frac{1}{n} \sum_{i=1}^n \left( Y_i - b + n(S_i(T) - e^{rT} S(0)) \right)$$

## Control Variates - przykłady

Klasyczne przykłady użycie metody control variates:

- ▶ instrument bazowy jako "zmienna kontrolna" dla zdyskontowanej wypłaty z opcji  $Y$ :

$$\bar{Y}(b_n) = \frac{1}{n} \sum_{i=1}^n \left( Y_i - b + n(S_i(T) - e^{rT} S(0)) \right)$$

- ▶ ceny "prostszych" opcji wyznaczone przy pomocy rozwiązań analitycznych mogą być zmienną kontrolną dla bardziej skomplikowanych instrumentów np. w modelu Blacka-Scholesa ceny geometrycznych opcji azjatyckich dla arytmetycznych opcji ajatyckich.

## Control Variates - przykłady

Klasyczne przykłady użycie metody control variates:

- ▶ instrument bazowy jako "zmienna kontrolna" dla zdyskontowanej wypłaty z opcji  $Y$ :

$$\bar{Y}(b_n) = \frac{1}{n} \sum_{i=1}^n \left( Y_i - b + n(S_i(T) - e^{rT} S(0)) \right)$$

- ▶ ceny "prostszych" opcji wyznaczone przy pomocy rozwiązań analitycznych mogą być zmienną kontrolną dla bardziej skomplikowanych instrumentów np. w modelu Blacka-Scholesa ceny geometrycznych opcji azjatyckich dla arytmetycznych opcji ajatyckich.
- ▶ w stochastycznych modelach stopy procentowej "zmienną kontrolną" mogą być ceny obligacji.

Zwykle istotną redukcję wariancji możemy uzyskać tylko dzięki znajomości specyficznych właściwości danego modelu / instrumentu.

# Importance Sampling

Metoda *Importance sampling* ma na celu redukcję wariancji poprzez zmianę miary prawdopodobieństwa, względem której generujemy ścieżki skupiając się na obszarach, które najbardziej wpływają na średnią. Chcąc wyestymować

# Importance Sampling

Metoda *Importance sampling* ma na celu redukcję wariancji poprzez zmianę miary prawdopodobieństwa, względem której generujemy ścieżki skupiając się na obszarach, które najbardziej wpływają na średnią. Chcąc wyestymować

$$\alpha = \mathbb{E}(h(X)) = \int h(x)f(x)dx,$$

gdzie  $f$  jest gęstością zmiennej  $X$ , bierzemy inną gęstość  $g$  taką, że  $f(x) > 0 \Rightarrow g(x) > 0$ . Wtedy

# Importance Sampling

Metoda *Importance sampling* ma na celu redukcję wariancji poprzez zmianę miary prawdopodobieństwa, względem której generujemy ścieżki skupiając się na obszarach, które najbardziej wpływają na średnią. Chcąc wyestymować

$$\alpha = \mathbb{E}(h(X)) = \int h(x)f(x)dx,$$

gdzie  $f$  jest gęstością zmiennej  $X$ , bierzemy inną gęstość  $g$  taką, że  $f(x) > 0 \Rightarrow g(x) > 0$ . Wtedy

$$\alpha = \int h(x)\frac{f(x)}{g(x)}g(x)dx = \mathbb{E}\left(h(X)\frac{f(X)}{g(X)}\right),$$

Jeśli  $X_1, \dots, X_n$  są niezależnymi próbkami z  $g$  mamy estymator:

$$\hat{\alpha}_g(n) = \frac{1}{n} \sum_{i=1}^n h(X_i) \frac{f(X_i)}{g(X_i)}$$



# Importance Sampling

Metoda *Importance sampling* ma na celu redukcję wariancji poprzez zmianę miary prawdopodobieństwa, względem której generujemy ścieżki skupiając się na obszarach, które najbardziej wpływają na średnią. Chcąc wyestymować

$$\alpha = \mathbb{E}(h(X)) = \int h(x)f(x)dx,$$

gdzie  $f$  jest gęstością zmiennej  $X$ , bierzemy inną gęstość  $g$  taką, że  $f(x) > 0 \Rightarrow g(x) > 0$ . Wtedy

$$\alpha = \int h(x)\frac{f(x)}{g(x)}g(x)dx = \mathbb{E}\left(h(X)\frac{f(X)}{g(X)}\right),$$

Jeśli  $X_1, \dots, X_n$  są niezależnymi próbkami z  $g$  mamy estymator:

$$\hat{\alpha}_g(n) = \frac{1}{n} \sum_{i=1}^n h(X_i) \frac{f(X_i)}{g(X_i)}$$

Ten estymator jest nieobciążony, a jego wariancja zależy od wyboru  $g$ . Aby uzyskać redukcję wariancji powinniśmy wybierać próbki proporcjonalnie do iloczynu  $h$  i  $f$ .

## Importance sampling - przykład

Zbieżność cen opcji call (put) zależy liczby ścieżek instrumentu bazowego będących powyżej (poniżej) ceny wykonania. Aby poprawić zbieżność dla opcji out-of-the-money zastosujemy metodę *importance sampling* tak aby względem nowej miary zdyskontowany proces cen akcji miał dryf zapewniający zwiększenie liczby ścieżek ponad (poniżej) ceny wykonania.

## Importance sampling - przykład

Zbieżność cen opcji call (put) zależy liczby ścieżek instrumentu bazowego będących powyżej (poniżej) ceny wykonania. Aby poprawić zbieżność dla opcji out-of-the-money zastosujemy metodę *importance sampling* tak aby względem nowej miary zdyskontowany proces cen akcji miał dryf zapewniający zwiększenie liczby ścieżek ponad (poniżej) ceny wykonania. Niech względem miary  $\mathbb{Q}^\theta$ :

$$dSt = (r + \sigma\theta)dt + \sigma dW_t^{\mathbb{Q}^\theta}$$

Z twierdzenia Girsanowa mamy

$$\frac{d\mathbb{Q}}{d\mathbb{Q}^\theta} \Big|_{\mathcal{F}_t} = e^{-\theta W_t^{\mathbb{Q}^\theta} - \frac{\theta^2}{2}t}$$

## Importance sampling - przykład

Zbieżność cen opcji call (put) zależy liczby ścieżek instrumentu bazowego będących powyżej (poniżej) ceny wykonania. Aby poprawić zbieżność dla opcji out-of-the-money zastosujemy metodę *importance sampling* tak aby względem nowej miary zdyskontowany proces cen akcji miał dryf zapewniający zwiększenie liczby ścieżek ponad (poniżej) ceny wykonania. Niech względem miary  $\mathbb{Q}^\theta$ :

$$dSt = (r + \sigma\theta)dt + \sigma dW_t^{\mathbb{Q}^\theta}$$

Z twierdzenia Girsanowa mamy

$$\frac{d\mathbb{Q}}{d\mathbb{Q}^\theta} \Big|_{\mathcal{F}_t} = e^{-\theta W_t^{\mathbb{Q}^\theta} - \frac{\theta^2}{2}t}$$

Wówczas biorąc przyrosty  $d\tilde{W}_t = dW_t + \theta dt$  i symulując  $\tilde{S}(t)$  cenę opcji liczymy jako

$$C(0, K) \approx e^{-rT} \left( \max(\tilde{S}(T) - K, 0) e^{-\theta W_T^{\mathbb{Q}^\theta} - \frac{\theta^2}{2}T} \right)$$

## Variate recycling

Często zależy nam nie tylko na tym aby wycenić instrument pochodny, ale też żeby wyznaczyć wrażliwość ceny na zmianę pewnych paramterów np.

$$\delta = \frac{\partial C}{\partial S}, \quad \text{vega} = \frac{\partial C}{\partial \sigma}$$

## Variate recycling

Często zależy nam nie tylko na tym aby wycenić instrument pochodny, ale też żeby wyznaczyć wrażliwość ceny na zmianę pewnych paramterów np.

$$\delta = \frac{\partial C}{\partial S}, \quad \text{vega} = \frac{\partial C}{\partial S}$$

Najczęściej estymuje się wrażliwości przy pomocy przybliżenia:

$$\frac{\partial v}{\partial p} \approx \frac{v(p + \delta p) - v(p)}{\delta p}.$$

## Variate recycling

Często zależy nam nie tylko na tym aby wycenić instrument pochodny, ale też żeby wyznaczyć wrażliwość ceny na zmianę pewnych paramterów np.

$$\delta = \frac{\partial C}{\partial S}, \quad \text{vega} = \frac{\partial C}{\partial S}$$

Najczęściej estymuje się wrażliwości przy pomocy przybliżenia:

$$\frac{\partial v}{\partial p} \approx \frac{v(p + \delta p) - v(p)}{\delta p}.$$

Można pokazać, że

$$\text{Var} \left( \frac{\partial v}{\partial p} \right) \approx \frac{2}{\delta p} \text{Var}(v(p)) (1 - \text{corr}(v(p + \delta p), v(p))),$$

oraz że dla monotonicznych funkcji  $v(p)$  korelacja jest dodatnia jeśli użyjemy tych samych realizacji ścieżek procesu Wienera. To znaczy użycie tych samych próbek przy obliczaniu  $v(p + \delta p)$  i  $v(p)$  (metoda *variate recycling*) przyspiesza zbieżność.

# Bibliografia

1. P. Glasserman, *Monte Carlo Methods in Financial Engineering*, Springer, 2003.
2. P. Jackel, *Monte Carlo Methods in Finance*, Wiley, 2002.